

Operaguas Analítica — Reporte técnico

Diplomado de Python y Análisis de Datos · Universidad Marista · 2026 Equipo: Emilio Rico Hernández y Andrés Rodríguez Morales.

Entrega: 25 de septiembre de 2026. **URL pública:** <https://operaguas-analitica.vercel.app> · **Repositorio:**

https://github.com/K4ppa1714/SISTEMA_DIPLOMADO

Este documento se genera con `python docs/reporte/generar.py`. Todo número viene de `analitica.resultados` (o de `pipeline/artefactos/resultados/*.json`), producido por código con semilla 42. Las interpretaciones marcadas **Validado por** fueron confirmadas por la persona indicada; las marcadas **VALIDAR** siguen pendientes de su revisión.

1. Resumen ejecutivo

Operaguas, organismo operador de agua de Huimilpan, necesita tres cosas: anticipar qué recibos no se pagarán a tiempo, detectar consumos anómalos (fugas) y atender las quejas más rápido. Construimos una capa de análisis e IA sobre una **simulación declarada** que reproduce la estructura de su sistema sin datos personales: un pipeline en Python que limpia, analiza y modela; una base en Supabase que guarda resultados, predicciones e índice semántico; y una aplicación web (Next.js + FastAPI en Vercel) con módulos de datos, modelos, señales y un asistente con triage, RAG y agente.

Hallazgos principales: - Cobranza: H1: $p = 0.374$ (no se rechaza H_0 , $\epsilon^2 = 0.002$). H2: $p = 1.12e-119$ (se rechaza H_0 , $V = 0.201$). Significancia no implica causalidad; el tamaño de efecto dice cuánto importa. - Modelo de pago tardío: Elegido por PR-AUC en validación cruzada temporal: `regresion_logistica` (PR-AUC prueba 0.428, ROC-AUC 0.718, F1 0.489) contra la regla del recibo anterior (PR-AUC 0.321, F1 0.421). Tasa real de atraso en prueba: 24.8%. - Fugas: Umbral fijado sin etiquetas (percentil 99.5 del periodo de referencia) y alarma con 24 h seguidas. Wavelets: 14 de 14 fugas, 7 falsas alarmas, retraso mediano 121.0 h. Nocturno: 14 de 14, 1 falsas, 47.0 h. Gana el flujo nocturno en F1: para una fuga constante, la hora de menor uso es la señal más limpia; Wavelets aporta la descomposición por escala y variables para modelos. `tiene_fuga` solo mide el acierto; nunca entra al detector. - Quejas: Con división por texto único el modelo logra F1 macro 0.926 en 83 textos nunca vistos (línea base 0.059); ponderado por quejas reales baja a 0.838 porque los textos que falla se repiten mucho. La división ingenua por fila da 1.000 porque 90.0 % de sus textos de prueba ya estaban en entrenamiento: esa cifra es fuga y no se usa.

2. Problema

El organismo factura mensualmente a cerca de quinientas tomas (en la simulación, 480 tomas y 14,400 recibos mensuales; 13,440 recibos tienen etiqueta de pago a la fecha de corte.) y conoce el atraso solo después de que ocurre. Las fugas se detectan por queja del usuario o por inspección, y las quejas se clasifican a mano. **Usuario:** dirección y área de atención de Operaguas.

3. Objetivo general

Dar a la dirección y al área de atención una herramienta desplegada que priorice la cobranza, señale tomas con probable fuga y agilice la atención de quejas, con métodos medidos y reproducibles.

4. Objetivos específicos

1. Construir un pipeline reproducible de limpieza con reglas explícitas contra la fuga de información.
2. Describir el comportamiento de consumo, cartera y quejas, y probar hipótesis con estadística inferencial.
3. Predecir el pago tardío por recibo con validación temporal y compararlo contra líneas base.
4. Analizar la serie de consumo en el tiempo y en frecuencia (Fourier y wavelets) para detectar fugas.
5. Clasificar quejas y encontrar quejas similares (NLP clásico contra embeddings).
6. Ofrecer un asistente con LLM: triage estructurado, RAG con fuentes y un agente con herramientas.

5. Fuente y descripción de los datos

Simulación declarada con la estructura del sistema de Operaguas (tarifas por tipo de ocupante, privadas, ciclo mensual de lectura y facturación, catálogo de quejas); los valores son supuestos. No contiene datos personales. El generador original no se conservó: la simulación **no puede regenerarse idéntica**; la reproducibilidad del proyecto parte de los CSV versionados en `data/simulados/` y de `pipeline/run_all.py` (decisión T-00c).


Datos analizados (simulación declarada)

tabla	filas	descripcion
tomas	480	tomas de la simulación (sin parámetros del generador)
recibos	14400	periodos 2024-04 a 2026-09
lecturas	14400	sin duplicados; nulas y retrocesos marcados
telemetria	115200	lecturas horarias de 40 tomas
quejas	1400	331 textos únicos

480 tomas y 14,400 recibos mensuales; 13,440 recibos tienen etiqueta de pago a la fecha de corte.

Columnas prohibidas como variables (fuga de datos o parámetros ocultos del generador): fecha_pago, dias_atraso, pagado, saldo_pendiente, propension_mora, consumo_base y tiene_fuga (solo validación).

6. Arquitectura



Fuente del diagrama: docs/arquitectura.md (mermaid).

- pipeline/ (Python, fuera de Vercel): limpieza, EDA, estadística, series, FFT, DWT, ML, DL, NLP e índice RAG. Escribe resultados (analitica.resultados), predicciones por lotes y embeddings.
- Supabase: esquemas raw, analitica, rag, agente, eval; RLS en todas las tablas; anon solo lee.
- api/ (FastAPI en Vercel): solo lo que depende de la pregunta del usuario (triage, RAG, agente, importe, salud).
- app/ (Next.js): presenta; un solo componente dibuja cualquier resultado.

7. Ingeniería de datos

Pasos del pipeline (pipeline/src/data/limpieza.py), con su efecto medido:

Pipeline de datos: qué hizo cada paso de limpieza

Paso	Resultado
Carga de tomas	480 filas x 10 columnas, 0 celdas nulas
Carga de lecturas	14,486 filas x 8 columnas, 230 celdas nulas
Carga de recibos	14,400 filas x 14 columnas, 1989 celdas nulas
Carga de telemetría	115,200 filas x 4 columnas, 0 celdas nulas
Carga de quejas	1,400 filas x 7 columnas, 0 celdas nulas
Lecturas: duplicados por (toma, periodo)	86 filas eliminadas (se conserva la lectura más reciente)
Lecturas: nulas	114 marcadas (no se imputan)
Lecturas: retrocesos de medidor	57 marcados como inconsistentes
Recibos: importes con tarifario CEA real	14400 recibos recalculados; total facturado 5,997,544 -> 19,405,612 MXN (mapeo {'domestico': 'domestico_medio', 'comercial': 'comercial', 'publico': 'publico_oficial', 'industrial': 'industrial'})
Recibos: pagados sin fecha de pago	67 recibos; se conserva la etiqueta original (la fecha no se imputa)

Paso	Resultado
Recibos: vencidos y sin pagar a la fecha de corte	122 etiquetados como pago tardío
Recibos: censura por fecha de corte	960 recibos con vencimiento posterior a 2026-09-01 quedan fuera del entrenamiento
Objetivo pago_tardío	tasa 24.9% en 13440 recibos etiquetados
Tabla de análisis	14400 filas x 33 columnas; 0 recibos sin lectura; sin consumo_base, propension_mora
Quejas	1400 quejas, 331 textos únicos: la división entrenamiento/prueba debe hacerse por texto único

Lecturas duplicadas: 86 filas eliminadas (se conserva la lectura más reciente); retrocesos: 57 marcados como inconsistentes; censura: 960 recibos con vencimiento posterior a 2026-09-01 quedan fuera del entrenamiento. Objetivo: tasa 24.9% en 13440 recibos etiquetados.


Decisiones: los duplicados de lectura se resuelven conservando la más reciente; las lecturas nulas y los retrocesos de medidor se **marcan y no se imputan**; los importes se recalculan con el tarifario CEA real (T-03); un recibo vencido y sin pagar a la fecha de corte cuenta como tardío y los recibos con vencimiento posterior quedan fuera del entrenamiento (censura).

Calidad de las lecturas de medidor


indicador	valor
lecturas nulas	114
retrocesos de medidor	57
medidores mudos	738
% inconsistentes	1.19

1.2% de las lecturas son inconsistentes; se marcan y no se imputan.


8. Análisis exploratorio (EDA)




Mediana doméstica 14.0 m³ contra 119.5 m³ industrial: los segmentos se analizan por separado porque sus escalas no son comparables.




El consumo doméstico promedio va de 13.2 a 17.8 m³ por toma (máximo en 2026-05, mínimo en 2025-01); la estacionalidad se analiza en T-06.




Mediana 669 MXN; el 90 % de los recibos domésticos está por debajo de 991 MXN (asimetría a la derecha por la tarifa escalonada).



Domiciliados 6.0% contra no domiciliados 28.9%; la privada con más atraso es Los Encinos (28.7%, n=812). Se prueba en H2.



El 30.0% de lo facturado en recibos etiquetados se pagó tarde o no se pagó a la fecha de corte.



Las tres categorías principales (sin_agua, fuga_toma, fuga_calle) suman 49% de las quejas; el canal más usado es telefono (34%).

Validado por Emilio (24/09/2026): la cartera tardía se concentra en tomas no domiciliadas; la domiciliación es la palanca de cobranza más clara que muestran los datos. El consumo doméstico tiene estacionalidad anual visible, que se analiza en la sección 10.

9. Estadística

Hipótesis definidas antes de ver los resultados: **H1** el consumo doméstico difiere entre privadas; **H2** pagar tarde depende de estar domiciliado.

Pruebas de hipótesis ($\alpha = 0.05$)

hipotesis	prueba	estadistico	gl	p_valor	efecto	decision
H1: el consumo doméstico difiere entre privadas	Kruskal-Wallis (promedio por toma)	9.718	9	0.3738	$\epsilon^2 = 0.002$	no se rechaza H0
H2: pagar tarde depende de estar domiciliado	chi² de independencia	541	1	1.124e-119	V de Cramér = 0.201	se rechaza H0

H1: $p = 0.374$ (no se rechaza H0, $\epsilon^2 = 0.002$). H2: $p = 1.12e-119$ (se rechaza H0, $V = 0.201$). Significancia no implica causalidad; el tamaño de efecto dice cuánto importa. **Tasa de pago tardío con IC 95 % (Wilson)**

segmento	n	tasa	ic95_inf	ic95_sup
tipo_tarifa=comercial	1568	0.2621	0.2409	0.2844
tipo_tarifa=domestico	11200	0.2402	0.2324	0.2482
tipo_tarifa=industrial	252	0.5595	0.4978	0.6195
tipo_tarifa=publico	420	0.2476	0.2088	0.2911
domiciliado=False	11088	0.289	0.2806	0.2975
domiciliado=True	2352	0.0604	0.0514	0.0707

El intervalo más ancho mide 12.2%: los segmentos pequeños (público, industrial) se interpretan con cautela. **Correlación de Spearman por toma (n = 480)**


variable_a	variable_b	rho	p_valor
consumo_medio	importe_medio	0.975	0
consumo_medio	antiguedad_meses	0.005	0.9076
consumo_medio	pct_lecturas_inconsistentes	0.042	0.3626
consumo_medio	tasa_tardio	0.113	0.01286
importe_medio	antiguedad_meses	0.012	0.7971
importe_medio	pct_lecturas_inconsistentes	0.06	0.1862
importe_medio	tasa_tardio	0.116	0.01131

variable_a	variable_b	rho	p_valor
antiguedad_meses	pct_lecturas_inconsistentes	-0.019	0.6831
antiguedad_meses	tasa_tardio	0.082	0.07241
pct_lecturas_inconsistentes	tasa_tardio	-0.07	0.1283

La variable más asociada a la tasa de pago tardío es importe_medio ($\rho = 0.12$, $p = 0.011$); consumo e importe correlacionan casi 1 por construcción de la tarifa.

Validado por Emilio (24/09/2026): la privada no explica el consumo doméstico (H1 no se rechaza), así que la zona no sirve para fijar metas de consumo; la domiciliación sí se asocia con puntualidad (H2), con un efecto entre pequeño y mediano ($V = 0.20$). Significancia no implica causalidad: es posible que quien domicilia ya fuera buen pagador.


10. Series temporales




Descomposición aditiva con periodo 12: el mes más alto es 5 (+3.81 m³ sobre la tendencia) y el más bajo 1 (-1.68 m³). La tendencia cambia 1.31 m³ en 30 meses: la estacionalidad domina, no el crecimiento. **Pronóstico de consumo mensual: prueba en los últimos 6 meses**

modelo	MAE	RMSE	MAPE_%
Ingenio estacional (mismo mes, año previo)	0.445	0.535	2.16
Holt-Winters aditivo (tendencia + estacionalidad 12)	0.454	0.517	2.18
Ingenio (último mes)	1.785	1.99	8.73

Con entrenamiento hasta 2026-03 y prueba 2026-04–2026-09, el mejor es «Ingenio estacional (mismo mes, año previo)» (MAE 0.445 m³ contra 1.785 del ingenio): modelar la estacionalidad es lo que reduce el error.



La media móvil pasa de 35.03 a 33.77 m³/día entre el inicio y el fin del periodo; la ventana de 7 días quita el ruido día a día y deja ver el cambio de nivel.



El rezago de 24 h (0.975) y el de 168 h (0.928) son mucho mayores que el de 12 h (-0.774): el consumo se repite cada día. Banda de significancia ± 0.037 . Estos rezagos son candidatos a variables (bloque E). **Cambio de régimen en el consumo diario (un punto de cambio en la media)**

indicador	valor
Fecha del cambio	2026-06-01
Media antes (m³/día)	35.05
Media después (m³/día)	33.44
Cambio relativo (%)	-4.58
t de Welch	3.456
valor p	0.00132

H_0 : la media diaria es igual antes y después de 2026-06-01. $p = 0.00132 < 0.05$: se rechaza H_0 ; el consumo baja 4.58 %. El total mezcla estacionalidad y fugas: un cambio en el agregado no dice qué tomas lo causan; eso lo resuelve el análisis por toma con Wavelets.

11. Feature engineering

Cada variable se conoce el día en que se emite el recibo; el historial de pagos usa solo recibos ya vencidos (el vencimiento del recibo anterior ocurre antes o el mismo día de la emisión del siguiente).

variable	justificación
tipo_tarifa	segmento de cliente; el EDA mostró tasas de atraso distintas por tarifa
privada	zona; captura diferencias socioeconómicas y operativas sin datos personales
domiciliado	H2: la asociación con el atraso es significativa (V de Cramér ≈ 0.20)
incluye_alcantarillado	cambia el importe (+10 %) y el tipo de servicio
incluye_saneamiento	cambia el importe (+12 %)
medidor_mudo	un recibo estimado puede generar inconformidad y retraso
lectura_inconsistente	misma razón: lecturas dudosas generan reclamos
consumo_m3	consumo del periodo facturado
total_pagar	monto a pagar con tarifario CEA; montos altos pueden retrasar el pago
antigüedad_meses	tiempo como cliente al emitir el recibo
mes	estacionalidad del calendario (aguinaldo, inicio de año)
tardio_anterior	comportamiento inmediato previo; se conoce al emitir (vencimiento anterior $\leq$ emisión)
tasa_tardio_historica	hábito de pago de la toma con recibos anteriores ya vencidos
tardios_ultimos_6	tendencia reciente del hábito de pago
recibos_con_historia	cuánta historia respalda las dos variables anteriores
consumo_vs_promedio_6	un salto de consumo (fuga, error de lectura) puede generar un recibo inesperado


12. Machine learning

Separación temporal (prueba = 4 últimos periodos con etiqueta), validación cruzada temporal por periodo, líneas base, tres modelos en Pipeline y un ensamble. El modelo se elige por PR-AUC en validación, nunca en prueba.

Modelos de pago tardío — prueba temporal (2026-04 en adelante, n=1920)

modelo	cv_pr_auc	umbral	pr_auc	roc_auc	f1	precision	recall	brier
base_mayoritaria	0.2491	0.5	0.2479	0.5	0	0	0	0.1865
base_regla_recibo_anterior		0.5	0.3208	0.6152	0.4214	0.4205	0.4223	0.2875
regresion_logistica	0.4482	0.48	0.4277	0.7182	0.489	0.3835	0.6744	0.2082
random_forest	0.4434	0.5	0.4262	0.7228	0.49	0.3875	0.666	0.206
gradient_boosting	0.4052	0.36	0.4355	0.7241	0.4708	0.3149	0.9328	0.2165
ensamble_votacion	0.4424	0.5	0.4327	0.7237	0.4937	0.3827	0.6954	0.2092


Elegido por PR-AUC en validación cruzada temporal: regresion_logistica (PR-AUC prueba 0.428, ROC-AUC 0.718, F1 0.489) contra la regla del recibo anterior (PR-AUC 0.321, F1 0.421). Tasa real de atraso en prueba: 24.8%.



La línea base mayoritaria marca el piso ($PR-AUC = \text{tasa de positivos}$); cualquier modelo útil debe superarla con claridad. **Matriz de confusión — regresion_logistica**

real	pred_a_tiempo	pred_tarde
a tiempo	928	516
tarde	155	321

Detecta 321 de 476 recibos tardíos (67%) con 516 falsas alarmas; el umbral se fijó en validación cruzada para maximizar $F1$.




Las variables que más aportan son `tardios_ultimos_6`, `tasa_tardio_historica`, `domiciliado`: el hábito de pago previo pesa más que el monto. Importancia no es causalidad. **Desempeño por tipo de tarifa (prueba)**


tipo_tarifa	n	tasa_real	recall	precision
comercial	224	0.2902	0.7385	0.4174
domestico	1600	0.2362	0.6561	0.3741
industrial	36	0.4444	1	0.4444
publico	60	0.2833	0.5294	0.3913

Los segmentos con pocos recibos (público, industrial) tienen métricas inestables; se analizan en T-09.

Análisis de errores (T-09):



Con el umbral elegido en CV (0.48) se marcan 837 recibos. Subir el umbral reduce falsas alarmas pero deja escapar más tardíos: la decisión depende de cuántas llamadas de cobranza puede hacer Operaguas.



La probabilidad predicha excede a la real en +0.20 en promedio (efecto de `class_weight='balanced'`). El ORDEN sí sirve: la tasa real crece de 2% en el decil más bajo a 51% en el más alto; se usa como puntaje de riesgo, no como probabilidad literal. **Perfil de aciertos y errores (promedios en prueba)**

grupo	n	domiciliado	tasa_tardio_historica	tardio_anterior	total_pagar	medidor_mudo
a tiempo correcto	928	0.334	0.119	0.069	1092	0.045
falsa alarma	516	0.002	0.391	0.413	1856	0.054
tardío NO detectado	155	0.161	0.19	0.187	1236	0.039
tardío detectado	321	0	0.426	0.536	1971	0.069

Los tardíos no detectados tienen historial de atraso de 19% contra 43% de los detectados: el modelo falla con quien casi nunca se atrasaba (atrasos 'nuevos'), algo que ninguna variable disponible al emitir el recibo anticipa. **Predicción por lotes de recibos aún no vencidos**


indicador	valor
recibos predichos	960
periodos	2026-08, 2026-09
marcados en riesgo	423
probabilidad media	0.4448

423 de 960 recibos por vencer quedan marcados en riesgo de pago tardío; la lista está en `analitica.predicciones_pago`.


Validado por Emilio (24/09/2026): el modelo sirve para ordenar la cobranza (el decil de mayor riesgo concentra la mayor tasa real de atraso), no para anunciar una probabilidad exacta. Sus fallas son los "atrasos nuevos" de tomas sin historial de atraso; ninguna variable disponible al emitir el recibo los anticipa.

Aprendizaje no supervisado (segmentación de tomas)

K-means sobre el comportamiento de consumo y pago de cada toma, con PCA para visualizarlo (`pipeline/src/ml/segmentos.py`).
Utilidad: separar a quién conviene ofrecer domiciliación o recordatorios.



El mejor K es 2 (silhouette 0.262); con valores menores a 0.5 los grupos se traslapan y deben leerse como tendencias, no como clases tajantes.



PC1 y PC2 explican 38% de la varianza; PC1 lo dominan tasa_tardio y domiciliado. Perfil de los 2 segmentos de tomas (medias)

segmento	nombre	tomas	consumo_medio	consumo_cv	estacionalidad	tasa_tardio	domiciliado	pct_lecturas_inconsistentes	antiguedad_meses
0	comportamiento típico	396	20.41	0.323	1.121	0.289	0	0.011	58.78
1	puntual, domiciliado	84	18.36	0.309	1.124	0.06	1	0.013	53.94

Segmentos: 0 = comportamiento típico (396 tomas); 1 = puntual, domiciliado (84 tomas). La separación principal es domiciliado/puntual contra el resto: la segmentación confirma H2 más que descubrir grupos nuevos.

13. Deep learning


MLP en PyTorch con las mismas variables y la misma separación temporal que el modelo clásico

(pipeline/src/deep_learning/mlp.py); se compara contra gradient boosting. No tiene que ganar: se reporta tal cual.

Red neuronal (MLP) contra Gradient Boosting — misma prueba temporal

modelo	pr_auc	roc_auc	umbral	f1
MLP PyTorch (64-32)	0.4251	0.7233	0.5	0.4874
Gradient Boosting	0.4275	0.7207	0.47	0.4929

Gana Gradient Boosting por PR-AUC (0.425 MLP contra 0.427 GB). La red tiene 4,289 parámetros y entrenó 12 épocas con parada temprana. En datos tabulares de este tamaño no supera a los árboles; GB es más simple de explicar y mantener.



La validación deja de mejorar en la época 2; la parada temprana evita el sobreajuste que se ve cuando la pérdida de entrenamiento sigue bajando.


14. NLP y embeddings

Clasificación de quejas por categoría: TF-IDF + regresión logística

Modelo	Evaluación	n prueba	Accuracy	F1 macro
TF-IDF + regresión logística	prueba por texto único	83	0.9639	0.9259
TF-IDF + regresión logística	prueba por texto único, ponderada por quejas	363	0.8375	0.8382
Línea base (clase más frecuente)	prueba por texto único	83	0.3614	0.059
TF-IDF + regresión logística	división ingenua por fila (CON FUGA, no válida)	350	1	1
TF-IDF + regresión logística	validación cruzada 5 pliegues (solo entrenamiento)	248		0.9782

Con división por texto único el modelo logra F1 macro 0.926 en 83 textos nunca vistos (línea base 0.059); ponderado por quejas reales baja a 0.838 porque los textos que falla se repiten mucho. La división ingenua por fila da 1.000 porque 90.0 % de sus textos de prueba ya

estaban en entrenamiento: esa cifra es fuga y no se usa.



Las categorías más débiles son fuga_toma (F1 0.67, 6 textos de prueba) y medidor (F1 0.67, 3 textos de prueba). Con tan pocos textos de prueba por clase, cada error mueve mucho la cifra. **Matriz de confusión (filas = real, columnas = predicha)**

real	atencion	baja_presion	calidad_agua	drenaje	facturacion	fuga_calle	fuga_toma	medidor	sin_agua
atencion	4	0	0	0	0	0	0	0	0
baja_presion	0	10	0	0	0	0	0	0	0
calidad_agua	0	0	5	0	0	0	0	0	0
drenaje	0	0	0	10	0	0	0	0	0
facturacion	0	0	0	0	3	0	0	0	0
fuga_calle	0	0	0	0	0	30	0	0	0
fuga_toma	0	0	0	0	0	0	3	3	0
medidor	0	0	0	0	0	0	0	3	0
sin_agua	0	0	0	0	0	0	0	0	12


Confusiones: 3 de fuga_toma → medidor. **Términos que más empujan a cada categoría (coeficientes del modelo)**

Categoría	Términos
atencion	nadie, todavia, revisar, reporte hace, todavia no
baja_presion	presion, chorro, debil, chorro sale, sale debil
calidad_agua	agua sale, tierra, turbia, sale turbia, turbia tierra
drenaje	drenaje, desbordado huele, desbordado, muy mal, huele muy
facturacion	recibo, cobrando, habia pagado, cobrando periodo, pagado
fuga_calle	tirando toda, tirando, saliendo calle, agua saliendo, fuga
fuga_toma	banqueta gotea, sin parar, gotea sin, gotea, llave
medidor	medidor, marca, llevaron medidor, toma no, caja
sin_agua	sin, abasto toda, toda calle, sin abasto, abasto

Cada categoría se explica con términos propios de su tipo de problema (atencion: nadie; baja_presion: presion; calidad_agua: agua sale...), así que la decisión del modelo se puede revisar término por término. **¿El texto de la queja determina su prioridad?**

Indicador	Valor
Textos únicos	331
Textos con más de una prioridad asignada	155
F1 macro TF-IDF + LR (CV agrupada por texto)	0.1791
F1 macro azar estratificado	0.256

155 de 331 textos aparecen con prioridades distintas y el modelo de texto (F1 0.179) no supera al azar (0.256): en esta simulación la prioridad no se deduce del texto. El triage no debe presentar la prioridad como predicción del texto.



Precision@5 (vecinos de la misma categoría): TF-IDF 0.894; LSA (SVD de TF-IDF, 100 dims) 0.894. Sentence-Transformers queda pendiente de ejecutar en un entorno con acceso a Hugging Face; no se reporta cifra hasta correrlo.

Validado por Andrés (24/09/2026): el clasificador sirve para enrutar quejas; la métrica honesta es la de texto único. La prioridad debe venir de reglas de negocio o de una persona, no del texto.

15. LLM

Tarea real: triage de quejas (POST /api/triage, api/_lib/triage.py).

- Categoría:** la da el clasificador de la sección 14, exportado a Python puro (sin scikit-learn en Vercel). Dos reglas declaradas corrigen confusiones observadas fuera de la simulación (fuga en vía pública → fuga_calle; "no hay agua" sin fuga → sin_agua); sobre los 331 textos simulados no cambian ninguna predicción.
- Prioridad:** reglas de negocio declaradas (api/_lib/prioridad.py), porque el texto no predice la prioridad (tabla nlp/prioridad_desde_texto). El LLM solo puede subirla un nivel si señala riesgo.
- LLM:** redacta el resumen y señala riesgo. **Control de prompt:** instrucciones fijas con el catálogo de categorías. **Formato:** JSON validado con Pydantic. **Errores:** 1 reintento ante salida inválida; respaldo Groq ante falla del proveedor; si todo falla, el triage responde con valido: false y un resumen extractivo. **Alucinaciones:** el resumen no puede agregar información; la categoría final nunca la decide el LLM. **Privacidad:** correos y números largos se ocultan antes de enviar el texto.

LLM en el triage: formato, acuerdo con el modelo y latencia


indicador	valor
textos	83
formato valido	1
reintentos promedio	0
acuerdo llm modelo	0.9639
exactitud llm	0.9639
exactitud sistema	1
salida marcada valida	0.9639
latencia p50 ms	1107
latencia p95 ms	20759
proveedores	gemini: 12, groq: 71

Sobre 83 textos de prueba, el LLM devolvió JSON válido en 100% y coincidió con el clasificador en 96%; la categoría final la da el clasificador y el LLM solo redacta el resumen y señala riesgo.

16. RAG

Documentos: tarifario CEA 2026-T3, reglas de cálculo del recibo portadas de Odoo y documentación de los datos simulados (pipeline/src/rag/corpus.py). **Chunking:** párrafos agrupados hasta 900 caracteres con solape de 150. **Embeddings:** Gemini de 768 dimensiones, el mismo modelo para indexar y consultar. **Índice:** pgvector en rag.fragmentos, consulta rag.buscar_fragmentos (coseno, Top-k). **Respuesta:** el LLM recibe solo los fragmentos y debe citarlos; la app muestra título, fragmento y similitud de cada fuente. **Sin evidencia:** si ninguna similitud supera el umbral, responde que no encontró información **sin llamar al LLM**.

Métrica del retriever (pipeline/src/rag/evaluar.py, solo preguntas validadas por Emilio):



Con 33 preguntas, el documento correcto aparece en el Top-5 en 82% de los casos (MRR 0.77); con 7 preguntas sin respuesta en los documentos, se abstiene correctamente en 14%.

17. Agentes

POST /api/agente (api/_lib/agente/): en cada turno el LLM elige **una** herramienta con argumentos en JSON; el dispatcher valida la decisión y los argumentos (Pydantic), ejecuta, mide el tiempo y devuelve la observación. Un argumento inválido, un dato inexistente o una herramienta que no existe vuelven al LLM como observación, sin romper la respuesta. **Límite:** 5 pasos. **Logging:** cada paso en agente.log (sesión, paso, herramienta, argumentos, resultado o error, milisegundos).

Herramienta	Argumentos	Fuente
estado_cuenta	id_toma	raw.recibos
calcular_importe	tipo_tarifa, consumo_m3, alcantarillado, saneamiento	api/_lib/tarifas.py
predecir_pago	id_toma, periodo opcional	analitica.predicciones_pago
buscar_documentos	pregunta, k	RAG (sección 16)
analizar_serie	tendencia, fourier o wavelets	analitica.resultados

Evaluación (pipeline/src/agents/evaluar.py, 30 casos con herramientas esperadas, 10 de varios pasos; solo los validados por Andrés):

Agente: selección de herramientas y éxito de tareas

indicador	valor
casos evaluados	30
Tool Selection Accuracy	0.7
primera herramienta correcta	0.7667

indicador	valor
éxito de tareas	0.7
éxito en tareas multipaso	0.5
pasos promedio	0.93

El agente eligió exactamente las herramientas esperadas en 70% de los casos y completó 70% de las tareas sin errores (50% en las de varios pasos).


18. Fourier



El pico dominante está en 1.0 ciclo(s) por día, es decir, un periodo de $24/1.0 = 24.0$ h (86.04 % de la energía). Un pico espectral indica una periodicidad, no su causa. **Frecuencias dominantes y su periodo**

frecuencia_ciclos_por_hora	ciclos_por_día	periodo_horas	energia_%
0.04167	1	24	86.04
0.08333	2	12	8.13
0.1667	4	6	1.28
0.125	3	8	0.77
0.0059	0.142	169.4	0.5


Periodo = $1/\text{frecuencia}$. El ciclo diario y sus armónicos (24, 12, 8, 6 h...) concentran 96.56 % de la energía: el patrón es un día con dos picos de uso (mañana y tarde), lo que sugiere planear presión y bombeo por franja horaria.



Con solo 6 de 1440 frecuencias la señal reconstruida explica $R^2 = 0.97$ de la variación horaria: el resto es ruido y cambios de nivel que la FFT no localiza en el tiempo (por eso se usan Wavelets).

Un pico espectral indica una periodicidad de la señal, no su causa.


19. Wavelets



Se eligió db4 porque su soporte corto localiza el inicio de una fuga y sus 4 momentos nulos separan el nivel base de los ciclos. En tomas con fuga, A5 concentra 77.41 % de la energía contra 69.18 % sin fuga: la fuga vive en la escala larga, no en el ciclo diario (D4). La

etiqueta solo se usa para comparar grupos.

Toma TF0590D064A: señal y aproximación A5 (promedio diario)



La aproximación A5 quita los ciclos de menos de ~64 h y deja ver el salto de nivel que empieza el 2026-06-16 (fuga simulada). Reconstruir con todos los niveles devuelve la señal con error máximo $4.9e-17$ m³/h: la DWT no pierde información. **Detección de fugas: Wavelets contra flujo mínimo nocturno**

metodo	umbral	VP	FP	FN	precision	recall	F1	retraso_mediano_h	precision_por_hora	recall_por_hora
Wavelet SWT db4 (A5/detalles)	1.667	14	7	0	0.667	1	0.8	121	0.995	0.819
Flujo mínimo nocturno 2-4 h (clásico)	1.481	14	1	0	0.933	1	0.966	47	1	0.964

Umbral fijado sin etiquetas (percentil 99.5 del periodo de referencia) y alarma con 24 h seguidas. Wavelets: 14 de 14 fugas, 7 falsas alarmas, retraso mediano 121.0 h. Nocturno: 14 de 14, 1 falsas, 47.0 h. Gana el flujo nocturno en F1: para una fuga constante, la hora de menor uso es la señal más limpia; Wavelets aporta la descomposición por escala y variables para modelos. tiene_fuga solo mide el acierto; nunca entra al detector. **Sensibilidad del detector Wavelet al umbral**

factor_umbral	umbral	VP	FP	FN	F1	retraso_mediano_h
0.8	1.334	14	26	0	0.519	101.5
1	1.667	14	7	0	0.8	121
1.2	2.001	14	0	0	1	134.5
1.5	2.501	11	0	3	0.88	163

Un umbral más bajo detecta antes pero arriesga falsas alarmas; uno más alto las evita pero tarda más. La tabla muestra qué tan estable es el resultado sin elegir el umbral con las etiquetas. **Anomalías detectadas contra quejas de fuga**

indicador	valor
Tomas con alarma	21
...con queja de fuga desde 7 días antes de la alarma	0

0 de 21 tomas con alarma tienen una queja de fuga cercana: en esta simulación las quejas no bastan para encontrar fugas, y la telemetría sí las señala. Cada alarma requiere inspección antes de actuar.

20. Evaluación integral

Componente	Métrica principal	Resultado
Pago tardío	PR-AUC en prueba temporal	Elegido por PR-AUC en validación cruzada temporal: regresion_logistica (PR-AUC prueba 0.428, ROC-AUC 0.718, F1 0.489) contra la regla del recibo anterior (PR-AUC 0.321, F1 0.421). Tasa real de atraso en prueba: 24.8%.
Fugas	precisión / recall por toma	Umbral fijado sin etiquetas (percentil 99.5 del periodo de referencia) y alarma con 24 h seguidas. Wavelets: 14 de 14 fugas, 7 falsas alarmas, retraso mediano 121.0 h. Nocturno: 14 de 14, 1 falsas, 47.0 h. Gana el flujo nocturno en F1: para una fuga constante, la hora de menor uso es la señal más limpia; Wavelets aporta la descomposición por escala y variables para modelos. tiene_fuga solo mide el acierto; nunca entra al detector.
Quejas	F1 macro por texto único	Con división por texto único el modelo logra F1 macro 0.926 en 83 textos nunca vistos (línea base 0.059); ponderado por quejas reales baja a 0.838 porque los textos que falla se repiten mucho. La división ingenua por fila da 1.000 porque 90.0 % de

Componente	Métrica principal	Resultado
		sus textos de prueba ya estaban en entrenamiento: esa cifra es fuga y no se usa.
Similitud	precision@5	Precision@5 (vecinos de la misma categoría): TF-IDF 0.894; LSA (SVD de TF-IDF, 100 dims) 0.894. Sentence-Transformers queda pendiente de ejecutar en un entorno con acceso a Hugging Face; no se reporta cifra hasta correrlo.
Segmentación	silhouette	El mejor K es 2 (silhouette 0.262); con valores menores a 0.5 los grupos se traslapan y deben leerse como tendencias, no como clases tajantes.
Deep learning	PR-AUC MLP contra GB	Gana Gradient Boosting por PR-AUC (0.425 MLP contra 0.427 GB). La red tiene 4,289 parámetros y entrenó 12 épocas con parada temprana. En datos tabulares de este tamaño no supera a los árboles; GB es más simple de explicar y mantener.
LLM (triage)	formato válido y acuerdo con el modelo	Sobre 83 textos de prueba, el LLM devolvió JSON válido en 100% y coincidió con el clasificador en 96%; la categoría final la da el clasificador y el LLM solo redacta el resumen y señala riesgo.
RAG	Recall@k y MRR (solo casos validados)	Con 33 preguntas, el documento correcto aparece en el Top-5 en 82% de los casos (MRR 0.77); con 7 preguntas sin respuesta en los documentos, se abstiene correctamente en 14%.
Agente	Tool Selection Accuracy y éxito de tareas	El agente eligió exactamente las herramientas esperadas en 70% de los casos y completó 70% de las tareas sin errores (50% en las de varios pasos).

21. Despliegue

Un solo proyecto de Vercel (cuenta de Emilio, plan gratuito) sirve la app Next.js y la API FastAPI en la misma URL. Los secretos viven solo en variables de entorno de Vercel. El pipeline pesado corre fuera de Vercel y deja sus resultados en Supabase. URL: <https://operaguas-analitica.vercel.app>.

22. Limitaciones

- Datos simulados: los resultados muestran el método, no el comportamiento real de Huimilpan; el generador no se conservó.
- Las probabilidades del modelo de pago están infladas por el balanceo de clases: se usan como puntaje de riesgo.
- Las fugas simuladas son escalones limpios; en datos reales habrá ruido y fugas graduales.
- Plan gratuito de Gemini: límites diarios bajos y uso del contenido por Google (aceptable solo con datos simulados).
- El corpus del RAG es pequeño; faltan la NOM-127, el contrato tipo y las preguntas frecuentes del portal.

23. Conclusiones

Validado por Emilio y Andrés (24/09/2026): el valor del proyecto está en conectar cada método con una decisión de Operaguas: a quién cobrar primero (modelo de pago), dónde revisar una fuga (flujo nocturno y wavelets) y cómo enrutar una queja (clasificador + triage). Las métricas se midieron con separación temporal o por texto único para no sobreestimarlas.

24. Trabajo futuro

- Probar con datos reales anonimizados de Operaguas y recalibrar el modelo de pago (calibración isotónica).
- Integrar la lista de riesgo a la cobranza y medir el efecto con un piloto A/B.
- Telemetría en más tomas y detección de fugas graduales.
- Ampliar el corpus del RAG con documentos oficiales.

Tabla de trazabilidad

Bloque	Qué se hizo y por qué	Código	Notebook	Datos	Resultado publicado (modulo/clave)	En la app	Mé evi
A. Python, datos, Pandas	Limpieza de lecturas (nullos, retrocesos, mudos), merge de recibos + lecturas + tomas, columnas prohibidas para evitar fuga de información	pipeline/src/data/limpieza.py, pipeline/src/config.py	01	lecturas, recibos, tomas	pipeline/informe_calidad · eda/calidad_lecturas · eda/resumen_datos	/datos	filas p de lin de lex incon
B. EDA	Distribuciones de consumo e importe, cartera, quejas por categoría y canal	pipeline/src/preprocessing/eda.py	02	dataset limpio	eda/consumo_por_tarifa · consumo_mensual · importe_domestico · cartera_mensual · tardio_por_segmento · quejas_por_categoria	/datos	gráfic concl

Bloque	Qué se hizo y por qué	Código	Notebook	Datos	Resultado publicado (modulo/clave)	En la app	Mé evi
C. Estadística	Kruskal-Wallis (consumo doméstico entre privadas), χ^2 (tardío contra domiciliación), IC 95 % de Wilson, Spearman	pipeline/src/preprocessing/eda.py	02	recibos, tomas	estadistica/pruebas_hipotesis · ic95_tardio · correlacion_spearman	/datos	valor hipótesis decis
D. Series de tiempo	Descomposición, media móvil, ACF por rezago, cambio de régimen (Welch), pronóstico con prueba en los últimos 6 meses	pipeline/src/signals/temporal.py	03	lecturas, telemetría	series/consumo_mensual_descomposicion · consumo_diario_movil · autocorrelacion_rezagos · cambio_regimen · prediccion_mensual	/temporal	MAE ingen ingen estac
E. Feature engineering	Rezagos, historial de pagos tardíos, consumo relativo, energía Wavelet por toma	pipeline/src/features/variables.py, pipeline/src/signals/temporal.py	04	recibos, lecturas, telemetría	ml/importancia_variables	/modelos	importancia por perm (PR-A)
F. ML supervisado	Pago tardío: línea base, regla del recibo anterior y 4 modelos con separación temporal ; análisis de errores y umbral	pipeline/src/ml/modelos.py, pipeline/src/ml/errores.py	04, 05	dataset final	ml/comparacion_modelos · comparacion_pr_auc · matriz_confusion · curva_umbral · calibracion · errores_por_segmento · perfil_errores · predicciones_resumen	/modelos	PR-A ROC-precisi recall
G. No supervisado	K-means + PCA sobre el comportamiento de consumo y pago de cada toma	pipeline/src/ml/segmentos.py	06	tomas agregadas	clustering/silhouette · segmentos_perfil · pca_segmentos	/modelos	silhouette K; valores explic
H. Pipelines y ensembles	Pipeline de scikit-learn, validación cruzada temporal, ensemble por votación, columnas prohibidas	pipeline/src/ml/modelos.py	04	dataset final	ml/comparacion_modelos	/modelos	CV P contra
I. Deep learning	MLP en PyTorch contra Gradient Boosting	pipeline/src/deep_learning/mlp.py	06	dataset final	dl/mlp_vs_gb · mlp_curva_perdida	/modelos	PR-A ambigüedad de pé
J. NLP clásico	TF-IDF + regresión logística para la categoría de queja, división por texto único	pipeline/src/nlp/clasificador.py	07	quejas	nlp/clasificacion_metricas · f1_por_categoria · matriz_confusion · palabras_clave · prioridad_desde_texto	/quejas	F1 métrica contra base de datos ingen
K. Embeddings	Búsqueda de quejas similares: TF-IDF contra LSA (y Sentence-Transformers cuando se corra)	pipeline/src/nlp/similitud.py	07, 08	quejas	embeddings/similitud_precision5	/quejas	precisión
L. LLM	Triage: resumen y riesgo con JSON validado, 1 reintento, respaldo Groq; la categoría la da el clasificador y la prioridad	api/_lib/triage.py, api/_lib/llm.py, api/_lib/prioridad.py, pipeline/src/nlp/evaluar_llm.py	07	textos de prueba de T-14	llm/triage_validacion (al correr el evaluador)	/asistente	forma de acierto modo latencia

Bloque	Qué se hizo y por qué	Código	Notebook	Datos	Resultado publicado (modulo/clave)	En la app	Mé evi
	reglas declaradas						
M. RAG	Corpus (tarifario CEA, reglas del recibo, documentación), chunking 900/150, embeddings 768, pgvector, umbral de evidencia, fuentes citadas	pipeline/src/rag/corpus.py, pipeline/src/rag/indexar.py, api/_lib/rag.py, pipeline/src/rag/evaluar.py	09	documentos del corpus	rag_eval/recall_mrr · preguntas (al correr el evaluador)	/asistente	Reca MRR abste corre
N. Agente	5 herramientas con argumentos validados, dispatcher, bitácora, límite de 5 pasos, tareas multipaso	api/_lib/agente/, pipeline/src/agents/evaluar.py	10	30 casos validados	agente_eval/tool_selection · casos (al correr el evaluador)	/asistente	Tool Accu de tai
O. Fourier	FFT del consumo horario, frecuencias dominantes → periodo, filtrado con 6 picos	pipeline/src/signals/temporal.py	03	telemetría	fourier/espectro · frecuencias_dominantes · reconstruccion_filtrada	/temporal	R ² de recon period pico (causa
P. Wavelets	DWT db4 de 5 niveles, energía por nivel, reconstrucción, detector de fugas contra flujo mínimo nocturno	pipeline/src/signals/temporal.py	03	telemetría, quejas	wavelets/energia_por_nivel · descomposicion_ejemplo · deteccion_fugas · sensibilidad_umbral · anomalias_vs_quejas	/temporal	F1 de contri méto
Despliegue	Next.js + FastAPI en Vercel, Supabase remoto, llaves solo en variables	next.config.ts, vercel.json, api/index.py	—	—	—	/ (estado de /api/salud)	URL /api